

辛庆宇

手机号码: 18360991278
出生年月: 2001.02

求职意向: AI 大模型研发

邮箱: 1339260251@qq.com
籍贯: 江苏淮安



教育背景

2024.9-2027.6	杭州电子科技大学	电子信息工程 (硕士)
2020.09-2024.06	常州大学	自动化 (本科)

专业技能

AI: 掌握 RAG、MCP、Agent 等 Ai 应用技术, 了解大模型微调与强化学习相关技术。
Java: 熟练掌握 JavaSE 编程, 如集合、IO 操作、反射、多线程、异常处理、JVM 等核心概念及应用。
框架: 熟悉使用 Spring、Spring Boot、MyBatis、LangChain、Spring AI 等后端开发框架, 能够完成分层架构设计与接口封装。
MySQL: 熟练 MySQL 数据库的使用, 包括索引优化、事务、日志、锁机制、分库分表、主从复制、存储引擎等基本原理。
Redis: 掌握 Redis 持久化, 掌握高并发下缓存击穿、穿透、雪崩问题的解决方案。

实习经历

2026.1-2026.4	熙牛医疗	Java 开发
故障排查与优化: 参与浙一 HIS 系统故障治理, 主导核心业务模块的问题定位与修复。 用户交付与问题处理: 负责维护用户交付群, 利用 AI 工具快速上手陌生医疗流程, 打通现场交付与后端开发的沟通壁垒, 高效响应线上用户反馈的功能异常与流程问题。同时建立标准化的故障排查文档, 沉淀了发药、号源池排班及退费处理规范, 显著提升了团队排障效率。		

项目经历

2026.04-2026.05	面试 agent	全栈开发
项目介绍: 本项目是一套基于大模型的智能面试辅助平台, 覆盖简历解析、模拟面试、知识库 RAG 问答、多智能体编排四大核心模块。系统采用 FastAPI + React 全栈架构, 通过 Redis Streams 实现异步任务流水线, 结合 pgvector 向量检索与多路召回重排序, 为用户提供从简历评估到模拟面试的完整 AI 辅助闭环。 核心技术: FastAPI、LangChain、PGVector、Redis、React、Docker 核心职责: 模拟面试引擎: 实现基于技能方向的题目生成与实时追问机制, 支持知识题与项目题的分类评估, 通过并发批量调用 LLM 将单轮面试评估耗时从串行 60s 压缩至 15s; 设计六档评分体系, 生成结构化面试报告。 RAG 知识库问答系统: 设计多通道检索架构 (向量相似度+BM25), 通过 Zhipu Embedding-3 生成 1536 维向量存入 pgvector, 经 Cross-Encoder 二次重排序后送入 LLM 生成回答, 支持 SSE 流式输出。实现 Query Rewrite 改写用户问题, 召回准确率较单通道提升约 30%。 智能下载: 设计两阶段架构 (计划 + 执行), 第一阶段通过 PlanningAgent 分析用户需求生成结构化下载计划 (含来源类型、URL、搜索关键词), 用户确认后进入第二阶段。执行阶段采用 DownloadExecutionAgent + GitHubExecutionAgent 分别处理网页抓取和 GitHub 仓库拉取; 执行完成后由 QualityAgent 进行质量检查, 不合格自动重试; 最终通过 SummaryAgen 整合多源内容为结构化文档并自动入库触发向量索引。全程通过 Redis 存储计划和进度状态, 前端轮询实现任务进度实时展示, 支持用户取消。		
2025.11-2026.01	Ai agent 智能助手系统	后端开发
项目介绍: 本项目是一套面向业务应用系统提效的综合智能体解决方案, 支持将执行过程中的各项能力 (如 Advisor、RAG、MCP) 抽象并存储于数据库, 实现自由配置和灵活编排。用户可根据实际业务场景, 动态组合和调整如 Draw.io 画图、AI 面试、日志检索等功能模块, 打造定制化的 Ai Auto Agent, 从而显著提升学习于工作效率。 核心技术: Spring AI (RAG、MCP、Advisor)、SpringBoot、MyBatis、MySQL、PGVector、Redis、React 核心职责:		

- **智能体组件动态装配与热更新**: 设计数据库驱动的组件装配方案, 通过责任链模式实现 Model、Prompt、MCP、Advisor 的动态装配, 并利用线程池并发读取多表, 将配置查询的 p99 延迟从 48ms 优化至 11ms, 耗时降低近 80%; 基于 Spring BeanDefinition 实现运行时动态注册为 Bean, 并采用 “定时删旧换新” 的方式实现不停机热更新。
- **Agent 执行链路设计**: 采用策略模式 + 责任链编排 Agent 的 “任务分析 -> 检索执行 -> 质量监督 -> 总结” 的标准化工作流程, 支持动态多轮执行。并通过传递同一个 DynamicContext 实现四个阶段间的内容共享和动态路由。
- **MCP 工具**: 基于 Stdio/SSE 两种通信方式, 将 CSDN 自动发文、ELK 日志检索通知等业务能力进行配置对接, 拓展 agent 业务能力。
- **RAG 知识库**: 基于 pgvector 实现向量数据库。通过 tenant_id 元数据过滤实现多租户隔离, 在检索阶段前置权限过滤, 并配合动态 Top-K, 提高检索精度。

2025.09-2025.11

商城优选

后端开发

- **项目介绍**: 基于 SpringBoot 的商城类 App 后端服务。支撑短信登录、探店点评、优惠券秒杀、抽奖、附近商户、智能客服等功能, 为客户端用户提供流畅的交互体验。
- **核心技术**: SpringBoot、Spring AI、MyBatis、MySQL、Redis、RocketMQ
- **核心职责**:
 - **异步秒杀**: 使用 RocketMQ 异步处理订单落库, 将响应时间从 460ms 优化至 140ms, 显著降低数据库压力
 - **超卖控制**: 使用 Redisson 分布式可重入锁+数据库乐观锁机制, 确保一人一单有效防止库存超卖
 - **智能客服**: 对接 GLM 大模型, 实现意图识别、工具调用、重试收敛的复杂交互, 保障用户体验
 - **缓存设计**: 针对高频查询场景, 设计并实现基于 Redis 集群的多级缓存架构, 优化缓存策略以提升性能。通过缓存空对象和布隆过滤器解决缓存穿透问题, 结合互斥锁和缓存预热有效防止缓存击穿, 显著降低数据库负载并提升响应效率。

2025.04-2025.09

船舶少样本分类系统

算法

- **项目介绍**: 基于 CLAP 音频大模型, 针对船舶噪声垂直领域做微调训练, 解决小样本条件下舰船分类任务精度低、泛化性差的问题, 提升水下声学目标识别能力。
- **核心技术**: Transformer、Python、PyTorch、Numpy
- **核心职责**:
 - **大模型微调**: 聚焦通用大模型垂直落地过拟合痛点, 基于 LoRA 低秩微调策略, 以轻量参数完成模型适配, 高效支撑多域快速迭代与场景化部署。
 - **多模态大模型迁移适配**: 基于 CLAP 音频 - 文本预训练大模型, 冻结主干网络+原型网络度量适配, 解决水声领域跨域迁移与小样本过拟合问题。
 - **语义引导特征增强**: 设计跨模态注意力 CMA 模块, 用文本语义先验校准音频特征, 缓解小样本下类间特征混叠。

个人评价

本人具备扎实的后端开发与算法研究能力, 热衷于技术钻研, 对待工作认真负责, 注重细节, 具备良好的团队协作能力。